

Fine-tuning de BART para la clasificación de sentimiento en reseñas turísticas

Lo que mide la etiqueta y lo que aprende el modelo

Documento técnico con la metodología CRISP-ML(Q)

Mateo Echeverría González · **Juan David López**

Grupo 5 (Team BART) · Docente: Edwin Alexander Puertas Del Castillo · Octubre de 2026

Integrante	GitHub	Kaggle
Mateo Echeverría González	MateoEG3	mateoro3
Juan David López	juandavidlopez5	juanlopez18

Roles: datos, modelado, evaluación y documentación, compartidos por los dos integrantes en todas las etapas (Tabla 23).

Repositorio	https://github.com/MateoEG3/traveler-insights-bart-g5
Notebook de Kaggle	https://www.kaggle.com/code/mateoro3/team-bart/notebook
Equipo en Kaggle	https://www.kaggle.com/mateoro3 · https://www.kaggle.com/juanlopez18
Competencia	https://www.kaggle.com/competitions/traveler-insights-uptc-2026

Resumen

Este trabajo aborda la competencia *Traveler Insights UPTC 2026*: clasificar reseñas turísticas de Sucre (Foursquare y Tripadvisor) en *negativo*, *neutral* o *positivo*. Siguiendo CRISP-ML(Q), ajustamos BARTO, un BART preentrenado en español, y lo comparamos con un baseline de TF-IDF y regresión logística y con el BART original en inglés, en nueve corridas trazables. El análisis exploratorio mostró que la etiqueta no proviene del texto: es un umbral sobre la valoración promedio del lugar, que una regla sencilla reproduce al 100 %. Por eso el BART que solo lee la reseña no supera al baseline (accuracy de 0,863 frente a 0,900 en un hold-out de 351 reseñas) y el preentrenado en inglés rinde igual que el de español. El modelo final, BART con el texto y los metadatos del lugar, obtiene una accuracy de 1,000 en validación cruzada, 0,997 en el hold-out y 1,00 en el leaderboard público, frente a 0,87 del baseline. La limitación principal es que ese resultado no mide comprensión del sentimiento: con la reseña vacía el modelo conserva su accuracy, y pierde hasta cuatro puntos si cambia el formato de la valoración. Cumple cinco de los seis criterios de éxito.

Palabras clave: clasificación de texto, BART, CRISP-ML(Q), validez de la etiqueta, aprendizaje por atajos, reseñas turísticas.

Estructura y convenciones. El documento sigue las seis fases de CRISP-ML(Q) [1]; cada fase termina con una tabla que relaciona los riesgos de calidad identificados con el método de QA aplicado y su evidencia (las Fases 5 y 6 comparten una). Los decimales se escriben con coma; las figuras, que salen directamente del cuaderno, usan punto. «CV» es la validación cruzada de 5 folds sobre las 806 reseñas de entrenamiento y «hold-out» son las 351 reseñas de test.csv. Las valoraciones se citan como aparecen en los datos (por ejemplo, 3.5/5). Todas las cifras provienen de la versión ejecutada del cuaderno del 7 de octubre de 2026; la categorización de errores (Tabla 13, Figura 8 y Anexo B) es la de la revisión manual del 8 de octubre.

Fase 1. Comprensión del negocio y de los datos

1.1 Objetivo de negocio y objetivo de ML

El usuario previsto es una entidad de turismo regional o un operador turístico de Sucre que necesita decidir, entre las reseñas que se publican sobre sus destinos, cuáles revisar primero. Le interesan sobre todo las desfavorables, porque suelen señalar problemas de aseo, seguridad o servicio que se pueden atender. La decisión que apoya el modelo es a qué lugares y a qué reseñas dedicar la atención del equipo.

En términos de aprendizaje automático es una clasificación de texto en tres clases. La entrada es el comentario de la reseña; en el modelo final se añaden la plataforma, el nombre del lugar y su valoración, que la competencia entrega en el mismo archivo. La salida es *negativo* (0), *neutral* (1) o *positivo* (2), y las etiquetas son la columna Sentimiento de los datos de la

competencia [2, 3]. La métrica oficial es la *accuracy*. Como una sola clase reúne el 78 % de las reseñas, la acompañamos siempre con el F1 macro.

1.2 Criterios de éxito y restricciones

Los criterios se fijaron en tres niveles antes de entrenar BART (Tabla 1). Los umbrales de ML se definen respecto al baseline de la Sección 3.1; por eso se calcularon después de entrenarlo y no se modificaron al conocer los resultados del Transformer. Los umbrales de inferencia y de tamaño se añadieron el 7 de octubre, antes de medir esas dos cantidades.

Tabla 1. Criterios de éxito definidos antes de entrenar BART.

Nivel	Criterio	Umbral
Negocio	Detectar reseñas negativas: recall de <i>negativo</i> en el hold-out	$\geq 0,50$ (el baseline detecta 4 de 10)
ML	F1 macro en el hold-out	$\geq 0,784$ (baseline + 0,03)
ML	Accuracy, la métrica oficial, en el hold-out	$\geq 0,900$ (no empeorar el baseline)
Económico	Entrenar una corrida completa de 5 folds en una GPU T4	≤ 15 min
Económico	Inferencia en GPU, por lotes	≤ 100 ms por reseña
Económico	Tamaño del modelo en disco	≤ 1 GB

Las restricciones fueron cuatro. De cómputo: una GPU Tesla T4 de Kaggle, con cupo semanal limitado. De tiempo: la competencia estuvo abierta seis días. De licencia: los dos checkpoints considerados se distribuyen bajo Apache 2.0, que permite el uso académico. Y de datos: 818 reseñas etiquetadas para entrenar.

1.3 Análisis exploratorio

La competencia entrega tres archivos con 1298 reseñas (Tabla 2). Su descripción indica que *test.csv* no trae etiqueta, pero sí la trae; el archivo que realmente se predice es *submission.csv*. Decidimos usar *test.csv* como hold-out local: no interviene en la selección de modelos ni de hiperparámetros.

Tabla 2. Archivos de la competencia, uso que se les dio y distribución de clases.

Archivo	Uso en el proyecto	Reseñas	Negativo	Neutral	Positivo
<i>train.csv</i>	Entrenamiento y validación cruzada	818	22 (2,7 %)	639 (78,1 %)	157 (19,2 %)
<i>test.csv</i>	Hold-out local	351	10 (2,8 %)	274 (78,1 %)	67 (19,1 %)
<i>submission.csv</i>	Envío a Kaggle (sin etiqueta)	129	—	—	—

Clases y plataforma. El desbalance es fuerte: predecir siempre *neutral* ya da una *accuracy* de 0,78. Al cruzar la clase con la plataforma aparece la primera anomalía (Figura 1): Tripadvisor solo tiene reseñas negativas y neutrales, y Foursquare solo neutrales y positivas. Ninguna plataforma tiene las tres clases.




Figura 1. Reseñas etiquetadas por plataforma y clase (train y hold-out). Cada plataforma tiene solo dos de las tres clases: en Tripadvisor no hay ningún *positivo* y en Foursquare ningún *negativo*.

Origen de la etiqueta. Esa combinación de clases llevó a revisar cómo se construyó la etiqueta, y ahí está el hallazgo central del proyecto. Sentimiento resulta de aplicar umbrales a *Valoración_num*, que es la calificación promedio del lugar y no la de la reseña, y sin llevar las dos plataformas a una misma escala: Foursquare califica de 0 a 10 y Tripadvisor de 0 a 5. La regla «*positivo* si la valoración es ≥ 7 , *neutral* si es ≥ 4 y *negativo* en otro caso» reproduce la etiqueta con una *accuracy* de 1,000 tanto en train como en el hold-out (Figura 2). De los 82 lugares (nombre y plataforma), ninguno tiene más de una etiqueta, y las 32 reseñas negativas vienen de solo dos: la Plaza de Majagual (28) y el Ecoparque Laderas de Villeros (4).

Esto tiene tres consecuencias que atraviesan el proyecto. Un modelo que lea la valoración acierta sin leer la reseña, lo cual es un atajo [4] y no análisis de sentimiento. Un modelo que solo lee el texto puede acertar únicamente de forma indirecta,




Figura 2. Valoración promedio del lugar y etiqueta de cada reseña. Los umbrales en 4 y 7 separan las tres clases sin ninguna excepción. Como Tripadvisor califica sobre 5, ninguno de sus lugares llega a *positivo*, por bien valorado que esté.

reconociendo la plataforma y el lugar por el estilo, la longitud y los nombres propios. Y la clase *negativo* no se puede generalizar a lugares nuevos, porque en estos datos es casi sinónimo de un lugar.

Longitud. Las reseñas de Foursquare son muy cortas (mediana de 7 palabras, máximo de 38) y las de Tripadvisor bastante más largas (mediana de 35, máximo de 618). Con el tokenizer de BARTO la mediana global es de 50 tokens, el percentil 95 de 203 y el máximo de 999; por plataforma, las medianas son 18 y 61 tokens (Figura 3).




Figura 3. Longitud de las reseñas en tokens de BARTO, por plataforma (eje horizontal logarítmico). La línea vertical marca la mediana: 18 tokens en Foursquare y 61 en Tripadvisor. La longitud, por sí sola, distingue bastante bien las dos plataformas.

Idioma y variantes. El corpus está en español; solo 4 reseñas traen fragmentos en inglés. Encontramos 19 con léxico colombiano o del Caribe (*chévere*, *bacano*, *mototaxi*), 2 con rasgos rioplatenses y 36 con emojis. En Foursquare, 53 de las 321 reseñas tienen palabras pegadas por la extracción (por ejemplo, «Lahamburguesa de pollo y elpatacónDoki»), frente a 6 de 977 en Tripadvisor.

Duplicados. Hay 33 filas repetidas en 16 grupos de texto idéntico: 8 grupos dentro de train, 3 entre train y el hold-out, y 5 que tocan el archivo de envío. Ningún grupo tiene etiquetas contradictorias.

Ejemplos ambiguos. Buscamos reseñas en las que el texto dice una cosa y la etiqueta otra. Con una lista corta de términos de elogio y de queja, 571 reseñas *neutral* (el 63 %) usan vocabulario claramente positivo, 8 reseñas *negativo* elogian sin ningún término de queja y 31 *positivo* o *neutral* contienen quejas explícitas. Tres casos: «Excelente servicio, he ido varias veces en 3 años 100% recomendada la empresa Coveñas Diving co.» está etiquetada *neutral* (5.0/5); «Es una plaza muy amplia, excelente para cualquier clase de evento de gran multitud, tiene varias diversiones para niños, y gran variedad de comidas» es *negativo* (3.5/5), y «Playas hermosas... Pero muy sucias. No hay canecas de la basura [...]» es *neutral* (4.0/5).

1.4 Verificación de la calidad de los datos

Etiquetas. No hay etiquetas inconsistentes en sentido estricto: ningún texto repetido tiene dos etiquetas y la regla de los umbrales no tiene excepciones. El problema es de validez, no de consistencia: la etiqueta es coherente con la valoración del lugar y no con el texto. **Textos vacíos.** No hay ninguno (se comprueba con una aserción al cargar), aunque 24 reseñas tienen una o dos palabras. **Datos personales.** No encontramos correos ni teléfonos; hay 2 URL, 1 usuario de red social y nombres de pila de guías y empleados. **Solapamiento.** El 97,7 % de las filas del hold-out y el 98,4 % de las del envío pertenecen a lugares que ya están en train, así que la evaluación mide sobre todo lugares conocidos.

1.5 Factibilidad e hipótesis de trabajo

¿Se puede resolver el problema con estos datos? Sí como tarea de la competencia, no como análisis de sentimiento. Predecir la etiqueta desde el texto solo es posible de manera indirecta, porque reseñas con la misma opinión reciben etiquetas distintas

según el lugar del que hablan. De ahí salen tres hipótesis. **H1**: un Transformer que solo lee el texto mejorará poco la accuracy del baseline, con un techo cercano a 0,90. **H2**: un modelo preentrenado en español no tendrá ventaja clara sobre uno preentrenado en inglés, porque la señal útil no es semántica. **H3**: con los metadatos del lugar en la entrada, la clasificación será casi perfecta. H1 se formuló antes de entrenar BART; H2 y H3 se escribieron con los primeros resultados ya a la vista, y así deben leerse.

1.6 Aseguramiento de calidad

Tabla 3. QA de la Fase 1: riesgo, método aplicado y evidencia.

Riesgo	Método de QA	Evidencia
Desbalance de clases	Conteo por clase y por plataforma	78 % <i>neutral</i> , 19 % <i>positivo</i> , 2,7 % <i>negativo</i> ; Tabla 2, Figura 1
Ruido o invalidez de la etiqueta	Reconstruir la etiqueta con una regla sobre <code>Valoración_num</code>	La regla acierta el 100 % en train y hold-out; Figura 2
Fuga entre train y test	Búsqueda de textos idénticos entre archivos y de lugares compartidos	8 grupos duplicados entre archivos; 97,7 % del hold-out es de lugares vistos
Atajos no lingüísticos	Longitud, palabras pegadas y año de la reseña por plataforma	El texto delata la plataforma (Figura 3), y la plataforma acota la clase
Datos personales	Expresiones regulares de correo, teléfono, URL y usuario	Ningún correo ni teléfono; 2 URL, 1 usuario y nombres de pila

Fase 2. Ingeniería de datos

2.1 Partición y control de fuga

Antes de partir eliminamos de train las 3 reseñas cuyo texto está también en el hold-out y dejamos un solo ejemplar de cada texto repetido (9 filas más), con lo que train pasó de 818 a 806 reseñas. Así ningún texto puede quedar a la vez en entrenamiento y en validación. Sobre esas 806 hicimos una validación cruzada estratificada de 5 folds con semilla 42. La preferimos a una única partición 80/20 porque, con 22 negativos, esta dejaría unos 4 en validación, muy pocos para decidir algo; con 5 folds cada negativo se evalúa exactamente una vez. Cada fold quedó con 4 o 5 negativos, 125 o 126 neutrales y 31 o 32 positivos. La partición se guarda en `folds.csv` y es la misma para el baseline y para todos los experimentos de BART. El hold-out se evalúa al final y no participa en ninguna decisión.

Dos salvedades. Una primera versión de la partición agrupaba los duplicados por fold y, con la versión de scikit-learn de Kaggle, dejó folds con entre 2 y 7 negativos; se corrigió quitando primero los duplicados, estratificando de forma exacta y añadiendo una aserción que exige 4 o 5 negativos por fold. Y no fue posible eliminar toda coincidencia con el archivo de envío: 5 de sus 129 textos aparecen también en train o en el hold-out, lo que no afecta la validación local.

2.2 Limpieza y normalización

La limpieza es mínima: normalización Unicode (NFC) y de espacios. No pasamos el texto a minúsculas ni quitamos tildes, signos o emojis, porque el tokenizer subword los maneja y aportan señal; un modelo de bolsa de palabras habría pedido más normalización que un Transformer. Tampoco separamos las palabras pegadas: es un artefacto de la extracción que queda documentado y que después se usa como prueba de robustez. Para buscar duplicados sí se compara una forma normalizada del texto (NFKC y minúsculas), que no es la entrada del modelo.

2.3 Tokenización y elección de `max_length`

La Tabla 4 muestra qué porcentaje de reseñas se truncaría con cada valor. Elegimos `max_length` = 384, que trunca el 1,2 % de las reseñas (el 1,5 % de Tripadvisor y ninguna de Foursquare). Con 256 se truncaría el 2,9 % y con 128 el 13,1 %; subir a 512 solo rescataría otro 0,7 % a cambio de más memoria y más tiempo. El truncamiento es al final: se conserva el inicio de la reseña, donde suele estar la valoración general, y el token de cierre `</s>`, del que depende la clasificación en BART. El costo de usar un valor menor se midió como experimento (E4, Sección 3.5).

Tabla 4. Porcentaje de reseñas truncadas según `max_length` (tokenizer de BARTO, 1298 reseñas).

<code>max_length</code>	32	64	128	192	256	384	512
Total (%)	75,0	34,8	13,1	6,0	2,9	1,2	0,5
Foursquare (%)	20,6	1,2	0,0	0,0	0,0	0,0	0,0
Tripadvisor (%)	92,8	45,9	17,4	8,0	3,8	1,5	0,6

2.4 Desbalance y aumento de datos

Tratamos el desbalance con pesos de clase inversos a la frecuencia en la función de pérdida, tanto en el baseline como en BART (experimento E3). Descartamos el sobremuestreo: los 22 negativos de train vienen de dos lugares, y repetirlos solo reforzaría la asociación entre la clase y esos lugares. Por una razón parecida no hicimos aumento de datos, que la guía deja como opcional: parafrasear o retrotraducir reseñas cuya etiqueta no depende del texto multiplicaría el ruido de etiqueta en lugar de reducirlo.

2.5 Aseguramiento de calidad

Tabla 5. QA de la Fase 2: riesgo, método aplicado y evidencia.

Riesgo	Método de QA	Evidencia
Fuga por duplicados	Quitar de train los textos del hold-out y dejar un ejemplar por texto	Aserciones: textos únicos en train y ninguno compartido con el hold-out
Folds desiguales o sin una clase	Estratificación exacta y aserción sobre los negativos por fold	Negativos por fold: 5, 4, 4, 4 y 5; las tres clases en todos
Esquema o etiquetas inesperados	Aserciones al cargar: ID únicos, tres clases, envío sin etiqueta y de 129 filas	La carga falla si algo no se cumple; pasó en todas las ejecuciones
Formato de envío ambiguo	Envío de prueba con el baseline	0,00 con etiquetas en texto; 0,87 con números (0, 1, 2)
Truncamiento excesivo	Tabla de truncamiento con el tokenizer del modelo	Tabla 4: 1,2 % con max_length = 384

Fase 3. Ingeniería del modelo

3.1 Baseline clásico

El baseline combina TF-IDF de palabras (unigramas y bigramas) y de caracteres (n-gramas de 2 a 5) con una regresión logística ($C = 10$), implementado con scikit-learn [5]. Se evaluó en los mismos folds y en el hold-out, junto con dos referencias que acotan el problema: la clase mayoritaria, que es el piso, y la variante que añade los metadatos del lugar, que muestra cuánto pesa el atajo (Tabla 6). El baseline oficial del grupo es B2, de solo texto y con pesos de clase. En el hold-out obtiene una accuracy de 0,900 (IC 95 % por bootstrap: [0,869; 0,932]) y un F1 macro de 0,754 ([0,609; 0,852]); detecta 4 de los 10 negativos y confunde 22 de los 67 positivos con *neutral* (Figura 4).

Tabla 6. Baselines en validación cruzada (CV) y en el hold-out.

ID	Modelo	CV		Hold-out	
		Acc.	F1 m.	Acc.	F1 m.
B0	Clase mayoritaria	0,778	0,292	0,781	0,292
B1	TF-IDF + reg. logística, texto	0,882	0,628	0,863	0,518
B2	B1 + pesos de clase	0,903	0,714	0,900	0,754
B3	B2 + metadatos del lugar	0,993	0,985	0,997	0,997
R	Regla sobre Valoración_num	1,000	1,000	1,000	1,000

		negativo	4	5	1
real	neutral	0	267	7	
	positivo	0	22	45	
		negativo	neutral predicho	positivo	

Figura 4. Matriz de confusión del baseline B2 en el hold-out.

Para entender qué aprende un modelo de solo texto hicimos tres pruebas con el mismo clasificador. La primera: predecir la plataforma a partir del texto da una accuracy de 0,943, es decir, el texto delata de dónde viene. La segunda: entrenando y evaluando dentro de cada plataforma, el modelo apenas supera a la clase mayoritaria (0,778 frente a 0,744 en Foursquare; 0,985 frente a 0,962 en Tripadvisor). La tercera: validando con lugares que no están en el entrenamiento, la accuracy baja a 0,833 y el F1 de *negativo* cae a 0,000. El baseline reconoce la plataforma y el lugar, no la queja.

3.2 Selección del checkpoint

El curso asignó a cada grupo una familia de modelos; a este le correspondió BART [6]. Comparamos dos checkpoints de esa familia (Tabla 7): BARTO [7], preentrenado solo con corpus en español, y el BART base original, preentrenado solo en inglés. Tienen la misma arquitectura, el mismo tamaño y la misma licencia, de modo que la única diferencia es el idioma de preentrenamiento y la comparación (E1 frente a E6) aísla cuánto aporta el español. La guía sugiere enfrentar un monolingüe

en español con un multilingüe; preferimos español frente a inglés porque mantiene fijo el tamaño. El candidato multilingüe natural, mBART-50 [8], es varias veces más grande y quedó fuera por costo de cómputo y por el tiempo disponible.

Tabla 7. Checkpoints comparados.

	BARTO (vgaraujov/bart-base-spanish)	BART base (facebook/bart-base)
Arquitectura	6 capas de encoder y 6 de decoder	La misma
Tamaño (medido al cargarlo)	140,0 millones de parámetros	140,0 millones de parámetros
Idioma de preentrenamiento	Solo español	Solo inglés
Licencia	Apache 2.0	Apache 2.0
Papel en el proyecto	Modelo principal (E1 a E5, E7 y E8)	Comparación (E6)

3.3 Arquitectura

BART es un Transformer [9] con encoder bidireccional y decoder autorregresivo, preentrenado para reconstruir texto corrompido [6]. La guía describe el caso de un encoder con cabeza de clasificación; en BART la clasificación funciona distinto y conviene dejarlo explícito. El mismo texto entra al encoder y al decoder; se toma el estado oculto del decoder en el último token ($\langle /s \rangle$) y se pasa por una cabeza de clasificación (capa densa, tanh y capa de salida de 3 clases) que no existe en el checkpoint y se inicializa al azar. Por defecto se ajustan todos los pesos. En el experimento E5 se congela el encoder junto con los embeddings, que BART comparte con el decoder, y quedan entrenables 58,1 de los 140,0 millones de parámetros: el decoder y la cabeza.

3.4 Configuración de entrenamiento

La configuración base (Tabla 8) se implementó con PyTorch [10] y Transformers [11]. Al final de cada época se predice la validación del fold; se conservan las predicciones de la mejor época según el F1 macro y el entrenamiento se detiene si pasan dos épocas sin mejora. De las dos GPU que entrega Kaggle usamos una sola, para que el tamaño de lote efectivo sea igual en todas las corridas.

Tabla 8. Configuración base de entrenamiento (experimento E1).

Elemento	Valor	Elemento	Valor
Optimizador	AdamW [12], <i>weight decay</i> 0,01	Función de pérdida	Entropía cruzada (con pesos de clase en E3, E7 y E8)
Learning rate	3e-5 (5e-5 en E2)	Parada temprana	F1 macro de validación, paciencia de 2 épocas
Scheduler	Lineal, con calentamiento en el 10 % de los pasos	Recorte de gradiente	Norma máxima de 1,0
Tamaño de lote	16	max_length	384 (128 en E4)
Épocas	Máximo 8	Semilla	42 (43 y 44 en E7a y E7b)

3.5 Diseño experimental y resultados

Cada experimento cambia una sola cosa respecto a su experimento base y entrena en los mismos 5 folds; el hold-out se predice promediando las probabilidades de los 5 modelos. La regla de selección quedó fijada antes de correr: entre los experimentos de solo texto (E1 a E6) gana el de mayor F1 macro en validación cruzada, sin mirar el hold-out ni el leaderboard. Ganó E3, que pasó a ser la base de E7a y E7b (otras semillas) y de E8 (la misma configuración con los metadatos del lugar en la entrada). La Tabla 9 reúne las nueve corridas, y el Anexo C da el detalle por fold.

Los resultados admiten tres lecturas. La primera es que ninguna variante de solo texto alcanza al baseline, cuyo F1 macro en validación cruzada es de 0,714 (Figura 6), y que casi todas quedan dentro del rango que produce cambiar únicamente la semilla: la configuración de E3 dio 0,673, 0,617 y 0,632 con tres semillas (media de 0,641 y desviación de 0,02). Lo único consistente es que los pesos de clase ayudan a *negativo*, cuyo F1 pasa de 0,083 a 0,303. Truncar a 128 tokens (E4) o congelar el encoder (E5) no mueve la accuracy, aunque en ambos casos el F1 de *negativo* cae a cero; E4, además, tarda la mitad. La segunda lectura es que el BART preentrenado en inglés rinde como BARTO (0,611 frente a 0,606). Si el modelo se apoyara en el significado del español, el de inglés debería perder; no pierde, y eso respalda H2. La tercera es que, con los metadatos del lugar, la clasificación es perfecta en validación cruzada, como anticipaba H3.

3.6 Curvas de entrenamiento y diagnóstico de sobreajuste

En los modelos de solo texto, la pérdida de validación toca su mínimo hacia la época 3 y después se estanca o sube, mientras la de entrenamiento sigue bajando (Figura 5): en E1 termina en 0,091 frente a 0,588 en validación. Es el patrón de sobreajuste

Tabla 9. Registro de experimentos de BART. Una corrida son 5 folds; el F1 macro de CV se calcula sobre las predicciones fuera de fold y se acompaña de la desviación entre folds. El tiempo es el de la corrida completa en una GPU T4.

ID	Cambio respecto a la base	Base	Validación cruzada			Hold-out		Épocas	Min
			Acc.	F1 macro	F1 neg.	Acc.	F1 macro		
E1	BARTO, configuración base	—	0,893	0,606 ± 0,041	0,083	0,875	0,559	4,2	20,1
E2	Learning rate 3e-5 → 5e-5	E1	0,887	0,573 ± 0,021	0,000	0,886	0,575	2,2	14,1
E3	Pesos de clase en la pérdida	E1	0,886	0,673 ± 0,099	0,303	0,886	0,632	4,8	21,1
E4	max_length 384 → 128	E1	0,891	0,577 ± 0,017	0,000	0,889	0,576	3,6	10,4
E5	Encoder congelado	E1	0,882	0,570 ± 0,013	0,000	0,880	0,568	4,2	14,9
E6	Checkpoint facebook/bart-base (inglés)	E1	0,901	0,611 ± 0,025	0,087	0,895	0,577	4,8	25,0
E7a	Semilla 42 → 43	E3	0,882	0,617 ± 0,045	0,133	0,878	0,567	5,6	24,6
E7b	Semilla 42 → 44	E3	0,868	0,632 ± 0,102	0,205	0,878	0,568	4,2	20,9
E8	Entrada: texto → texto + metadatos del lugar	E3	1,000	1,000 ± 0,000	1,000	1,000	1,000	3,6	21,3

que cabe esperar con unos 645 ejemplos de entrenamiento por fold y 140 millones de parámetros. La parada temprana lo contiene, porque conserva las predicciones de la mejor época de cada fold. En E8 las dos curvas bajan juntas hasta cero: la señal está en la entrada y el modelo la encuentra en tres o cuatro épocas.




Figura 5. Pérdida de entrenamiento y de validación por época en cada experimento (promedio de los 5 folds). La línea punteada marca la mejor época media. De E1 a E7 la validación deja de mejorar mientras el entrenamiento sigue bajando; en E8 las dos curvas convergen a cero.

3.7 Trazabilidad

Todas las corridas se hicieron en Kaggle con una GPU Tesla T4, Python 3.13.15, PyTorch 2.11.0 (CUDA 12.8), Transformers 5.16.1, scikit-learn 1.6.1, pandas 2.3.3 y NumPy 2.1.3. Las semillas están fijadas y se activan las operaciones deterministas de PyTorch. El registro es experimentos.csv: una fila por corrida con su configuración, métricas, tiempo, hardware y fecha. Cada experimento terminado se guarda además en disco con una firma de la partición, de modo que una ejecución posterior lo recupera en lugar de entrenarlo otra vez, pero solo si la configuración y los folds son idénticos. El entrenamiento completo de las nueve corridas se hizo el 7 de octubre de 2026 y tomó unas tres horas de GPU; las versiones posteriores del cuaderno recuperan esos experimentos desde un dataset privado de Kaggle y reentrenan únicamente los dos modelos finales. Sin ese dataset, el cuaderno entrena todo desde cero.

Sobre la reproducibilidad hay tres evidencias: los dos primeros folds de E1 dieron exactamente los mismos valores (0,603 y 0,560) en dos sesiones distintas; las cifras del baseline en el hold-out coinciden entre Kaggle y una ejecución en otro entorno,




Figura 6. F1 macro en validación cruzada de cada experimento; la barra de error es la desviación entre folds y la línea punteada, el baseline B2 (0,714). Solo E8, que lee los metadatos del lugar, lo supera.

con otra versión de scikit-learn, y las métricas de los dos modelos finales en el hold-out se repitieron en tres ejecuciones completas del cuaderno. La única variación observada fue una predicción de 129 en el archivo de envío del modelo de solo texto.

3.8 Aseguramiento de calidad

Tabla 10. QA de la Fase 3: riesgo, método aplicado y evidencia.

Riesgo	Método de QA	Evidencia
Error silencioso en el pipeline	Prueba de humo antes de gastar GPU: una época con pocos ejemplos por cada camino (dos checkpoints, encoder congelado, pesos, metadatos, guardar y recargar)	Aserciones: un solo <code></s></code> por texto, longitud $\leq \text{max_length}$, probabilidades que suman 1, pérdida finita; pasa en 32 s
Resultados no comparables	Mismos folds y semilla; un solo cambio por experimento	Columna «Base» de la Tabla 9 y de <code>experimentos.csv</code>
Sobreajuste	Parada temprana y curvas por época	Figura 5
Diferencias debidas al azar	Tres semillas de la configuración elegida; desviación entre folds	Desviación de 0,02 entre semillas; barras de la Figura 6
Sobreajuste al leaderboard público	El modelo se elige con validación cruzada; el hold-out se evalúa una vez; envíos contados	Tres envíos en total, ninguno usado para elegir (Sección 4.2)

Fase 4. Evaluación del modelo

4.1 Modelo final y modelo de referencia

El modelo final del proyecto es BARTO con el texto y los metadatos del lugar, es decir, la configuración de E8. Lo elegimos por la validación cruzada (accuracy de 1,000 frente a 0,886 del mejor modelo de solo texto) y no por el leaderboard; las columnas que usa vienen en el archivo de envío de la competencia. Su entrada tiene esta forma: Sitio: Foursquare | Lugar: Philadelphia | Valoración: 6.9/10 | La hamburguesa ranch es deliciosa.

Conviene decir sin rodeos qué hace: acierta porque lee la valoración y el nombre del lugar, no porque interprete la opinión. Por eso conservamos como modelo de referencia el mejor BART de solo texto (E3), que muestra hasta dónde se llega leyendo únicamente el comentario y que es, además, el único con errores suficientes para analizar. Los dos se reentrenaron con las 806 reseñas de train durante el número de épocas que resultó mejor en promedio en la validación cruzada (4 y 5, respectivamente), y el hold-out se evaluó una sola vez.

4.2 Métrica oficial, métricas complementarias e incertidumbre

La Tabla 11 reúne la métrica oficial en validación local y en el leaderboard público, y la Tabla 12 la precisión, el recall y el F1 por clase. Los intervalos de confianza se obtuvieron por bootstrap con 2000 remuestreos del hold-out [13].


Para comparar cada modelo con el baseline usamos un bootstrap pareado, que remuestrea las mismas reseñas para los dos. La diferencia de accuracy del BART de solo texto es de $-0,037$, con un intervalo de $[-0,077; +0,003]$: no se distingue del baseline. La del modelo final es de $+0,097$ $[+0,068; +0,128]$. Entre semillas, la configuración de solo texto varía poco en

Tabla 11. Métrica oficial (accuracy) y F1 macro, con intervalos de confianza del 95 % en el hold-out.

Modelo	Acc. CV	Acc. hold-out	F1 macro hold-out	Errores	Leaderboard
Baseline B2 (TF-IDF + reg. logística)	0,903	0,900 [0,869; 0,932]	0,754 [0,609; 0,852]	35	0,87
BART solo texto (referencia)	0,886	0,863 [0,826; 0,897]	0,606 [0,536; 0,693]	48	no enviado
BART texto + metadatos (final)	1,000	0,997 [0,991; 1,000]	0,982 [0,932; 1,000]	1	1,00

Tabla 12. Precisión (P), recall (R) y F1 por clase en el hold-out, a partir de las matrices de la Figura 7.

Clase	Reseñas	Baseline B2			BART solo texto			BART texto + metadatos		
		P	R	F1	P	R	F1	P	R	F1
Negativo	10	1,000	0,400	0,571	0,200	0,100	0,133	1,000	0,900	0,947
Neutral	274	0,908	0,974	0,940	0,938	0,883	0,910	0,996	1,000	0,998
Positivo	67	0,849	0,672	0,750	0,682	0,896	0,774	1,000	1,000	1,000
Promedio macro	351	0,919	0,682	0,754	0,607	0,626	0,606	0,999	0,967	0,982

**Figura 7.** Matrices de confusión en el hold-out. El BART de solo texto acierta 1 de los 10 negativos y manda 28 reseñas *neutral* a *positivo*; el modelo final falla una sola reseña.

accuracy ($0,880 \pm 0,004$ en el hold-out) y bastante más en F1 macro ($0,589 \pm 0,031$), que con 10 negativos depende de uno o dos aciertos.

En Kaggle se hicieron tres envíos y ninguno se usó para elegir el modelo. El primero, el baseline con las etiquetas en texto, obtuvo 0,00 y sirvió para descubrir que el formato esperado es numérico; el segundo, el mismo baseline con números, obtuvo 0,87; el tercero, el modelo final, 1,00. El 0,87 es coherente con el 0,900 local: con 129 filas, cada reseña pesa cerca de 0,8 puntos.

4.3 Análisis de errores

Como el modelo final comete un solo error en el hold-out, el análisis se hizo sobre el modelo de solo texto, que comete 48. Revisamos manualmente los 48, y no solo los 20 que pide la guía: leímos cada reseña con su etiqueta, su predicción y los datos del lugar, y le asignamos una categoría y una hipótesis de causa (Tabla 13 y Figura 8; la lista completa está en el Anexo B).


**Figura 8.** Distribución de los 48 errores del modelo de solo texto por categoría, según la revisión manual. Más de la mitad (26) son errores de etiqueta: el texto y la etiqueta dicen cosas distintas.

Tabla 13. Categorías de error del modelo de solo texto en el hold-out según la revisión manual, con un ejemplo y la hipótesis de causa. Entre paréntesis, la confianza del modelo en su predicción.

Categoría	n	Ejemplo (etiqueta → predicción)	Hipótesis de causa
Error de etiqueta	26	«La hamburguesa ranch es deliciosa» (ID 257, 6.9/10; neutral → positivo, 0,99). «La famosa y monumental plaza de Majagual, adornada con hermosos espejos de agua y fuentes [...] Recomendado.» (ID 880, 3.5/5; negativo → neutral, 0,79)	El texto es un elogio explícito y la etiqueta es <i>neutral</i> o <i>negativo</i> : la discrepancia está en la etiqueta, que sale de la valoración del lugar, y no en el modelo.
No es una reseña	7	«Las pizzas de» (ID 312; neutral → positivo, 0,98)	Fragmento incompleto, sin contenido suficiente para expresar una opinión. La categoría incluye también listas, preguntas y respuestas del negocio.
Reseña mixta	7	«Las playas de Tintipan hermosas, tranquilas y muy bien cuidadas [...] deben mejorar la gastronomía y el servicio» (ID 895; neutral → negativo, 0,52)	Elogia las playas pero introduce una condición negativa: la valoración es mixta.
Texto con ruido	4	«Elsolomilllorecomendado,lomodel chef tambien [...] ybuen servicio.» (ID 183; positivo → neutral, 0,82)	Las palabras están concatenadas y deformadas, lo que dificulta identificar la opinión.
Crítica no detectada	2	«Feas playas, mejor la segunda ensenada...» (ID 261; neutral → positivo, 0,99)	La etiqueta <i>neutral</i> es parcialmente plausible, pero el texto trae una crítica explícita que el modelo ignoró.
Sesgo de plataforma	1	«Un centro comercial decente en sincejejo!» (ID 285; neutral → positivo, 0,99)	«Decente» es una valoración tibia, compatible con <i>neutral</i> ; el modelo pudo asociar Foursquare con <i>positivo</i> .
Negación	1	«Por cierto, no es que sea la gran cosa estar aqui.» (ID 286; neutral → positivo, 0,90)	La negación invierte o atenúa el significado de la expresión positiva.
Regionalismo	0	–	Ningún error se atribuye a un regionalismo.
Ironía	0	–	No se encontró ningún caso.

La categoría dominante es el error de etiqueta, con 26 de 48: reseñas favorables marcadas *neutral* o *negativo* porque la etiqueta sale de la valoración del lugar. En tres de ellas (ID 305, 468 y 585) el modelo predijo *negativo* con una confianza menor de 0,5: la etiqueta es discutible, pero el modelo tampoco habría acertado con la etiqueta corregida. En las dos críticas no detectadas el modelo predice *positivo* con una confianza de 0,98 o más, lo que confirma que se guía por el estilo de la plataforma y no por la polaridad. No encontramos ironía, y ningún error se explica por un regionalismo: la reseña 288 («Super cheveree muy bn») usa un registro regional, pero es un elogio marcado *neutral*. Un modelo que entendiera mejor el español no corregiría la mayoría de estos casos.

El único error del modelo final es la reseña 886, un *negativo* del Ecoparque Laderas de Villeros que el modelo marca *neutral* aunque el 3.5/5 está en su entrada. Ese lugar tiene solo 3 reseñas en train. El caso indica que el modelo no aprendió el umbral como regla general: para *negativo* se apoya sobre todo en el nombre del lugar, y un lugar poco visto con valoración baja se le escapa.

4.4 Robustez

Perturbamos el texto de las 351 reseñas del hold-out de ocho maneras y, para el modelo final, hicimos además tres pruebas sobre los metadatos (Tabla 14).

Tabla 14. Robustez en el hold-out: accuracy tras cada perturbación y cambio frente al valor sin perturbar (0,863 y 0,997).

Perturbación	BART solo texto		BART texto + metadatos	
	Accuracy (cambio)	Predicciones que cambian	Accuracy (cambio)	Predicciones que cambian
Erratas en el 5 % de las letras	0,832 (−0,031)	6,8 %	0,997 (0,000)	0,0 %
Erratas en el 15 % de las letras	0,684 (−0,179)	23,4 %	0,997 (0,000)	0,0 %
Sin tildes y en minúsculas	0,855 (−0,009)	4,3 %	0,997 (0,000)	0,0 %
Todo en mayúsculas	0,219 (−0,644)	72,1 %	0,997 (0,000)	0,0 %
Palabras pegadas (30 % de los espacios)	0,849 (−0,014)	1,7 %	0,997 (0,000)	0,0 %
Variantes regionales (<i>muy</i> → <i>re</i> , <i>bueno</i> → <i>bacano</i> ...)	0,858 (−0,006)	1,4 %	0,997 (0,000)	0,0 %
Texto largo (reseña repetida 4 veces)	0,835 (−0,028)	14,2 %	0,994 (−0,003)	0,3 %
Texto corto (primeras 8 palabras)	0,191 (−0,672)	74,4 %	0,997 (0,000)	0,0 %
Texto de la reseña vacío (solo metadatos)	–	–	0,997 (0,000)	0,0 %
Sin valoración (se reemplaza por «?»)	–	–	0,957 (−0,040)	4,0 %
Valoración de Tripadvisor en escala de 10 (4.5/5 → 9.0/10)	–	–	0,969 (−0,028)	2,8 %

El modelo de solo texto tolera quitar tildes, pegar palabras o introducir variantes regionales, con pérdidas de alrededor de 0,01. Con erratas en el 15 % de las letras baja a 0,68. Y se derrumba con dos cambios que no alteran la opinión: con el texto en mayúsculas queda en 0,22 y con solo las primeras 8 palabras en 0,19. Clasifica por la forma del texto, es decir, por la longitud

y la apariencia que delatan la plataforma, y no por lo que dice. Al modelo final ninguna perturbación del texto lo mueve, y con la reseña vacía conserva la misma accuracy sin cambiar una sola predicción: no usa la reseña. Lo que sí lo afecta son los metadatos. Sin valoración baja a 0,957, y con la valoración de Tripadvisor en otra escala, a 0,969. Es estable mientras lleguen los mismos lugares con el mismo formato de valoración, y solo en ese caso. Las cifras de las perturbaciones aleatorias varían en la tercera decimal entre ejecuciones.

4.5 Explicabilidad

Usamos atribución por oclusión [14]: se quita una palabra a la vez y se mide cuánto baja la probabilidad de la clase predicha. No usamos la atención como explicación, porque los pesos de atención no equivalen a importancia [15]. La oclusión tampoco es una explicación causal completa: no captura interacciones entre palabras y depende de cómo se parte el texto.

En el ejemplo de la Figura 9 (ID 257, Foursquare, 6.9/10, etiqueta *neutral*), el modelo final predice *neutral* con 0,99, y quitar el fragmento 6.9/10 hace caer esa probabilidad en 0,99; las palabras de la reseña aportan cerca de cero. El modelo de solo texto predice *positivo* con 0,99 para la misma reseña y ninguna palabra pesa más de 0,01. En una reseña *negativo* de la Plaza de Majagual (ID 866), lo que más sostiene la predicción del modelo final es la palabra «Plaza», que identifica al lugar (0,16), más que la valoración (0,02); concuerda con el error de la reseña 886. En una reseña *positivo* de Foursquare (ID 56), ninguna palabra pesa más de 0,01: la plataforma y la valoración son señales redundantes y, al quitar una, queda la otra. Este último caso ilustra el límite de ocluir de a una palabra.




Figura 9. Atribución por oclusión del modelo final en la reseña 257: caída de la probabilidad de *neutral* al quitar cada palabra de la entrada. Toda la predicción descansa en el fragmento 6.9/10; el texto de la reseña no aporta.

4.6 Responsabilidad: sesgos y privacidad

La Tabla 15 compara el acierto de los dos modelos por subgrupo. **Sesgo por plataforma:** las clases dependen de dónde se publicó la reseña, de modo que la misma opinión recibe etiquetas distintas; el modelo de solo texto acierta 0,92 en Tripadvisor y 0,70 en Foursquare. **Sesgo por destino:** acierta 0,96 en San Onofre y 0,63 en Sincelejo, y como las 32 reseñas negativas vienen de dos lugares, un lugar nuevo con malas reseñas no sería detectado. **Sesgo por registro:** las reseñas breves e informales se parecen a las de Foursquare y tienden a recibir *positivo* (0,77 en las de 1 a 5 palabras frente a 0,99 en las de más de 60). Las variantes regionales, en cambio, casi no lo afectan (−0,006), y el inglés es demasiado escaso en los datos (4 reseñas) para medirlo.

Tabla 15. Accuracy por subgrupo en el hold-out (global: 0,863 con solo texto y 0,997 con el modelo final). Con menos de 20 reseñas el valor es solo indicativo; se omiten Corozal (4), Sincé (6) y Tolú (2).

Subgrupo	n	% neutral	Solo texto	Final	Subgrupo	n	% neutral	Solo texto	Final
Foursquare	90	25,6	0,700	1,000	De 1 a 5 palabras	34	23,5	0,765	1,000
Tripadvisor	261	96,2	0,920	0,996	De 6 a 20	87	58,6	0,793	1,000
Sincelejo	81	48,1	0,630	1,000	De 21 a 60	161	91,3	0,870	0,994
Coveñas	127	82,7	0,929	0,992	Más de 60	69	98,6	0,986	1,000
San Onofre	120	95,0	0,958	1,000	Hasta 2014	85	49,4	0,682	1,000
Santiago de Tolú	11	100,0	0,818	1,000	De 2015 a 2018	139	77,7	0,892	0,993
Lugar no visto en train	8	50,0	0,875	1,000	De 2019 en adelante	127	97,6	0,953	1,000

Privacidad. No hay correos ni teléfonos, pero sí nombres de pila de guías y empleados y un usuario de red social. Los datos son públicos [3]; aun así, en este documento no se citan reseñas que nombren personas, y el modelo no debe usarse para

perfilar a nadie. **Uso indebido.** La salida no es el sentimiento de una reseña sino una estimación de la franja de valoración del lugar; presentarla como la opinión de un visitante concreto sería engañoso. **Mitigaciones.** Declarar el origen de la etiqueta, reportar los resultados por plataforma y por lugar y, para un uso real, reetiquetar una muestra según el contenido del texto y llevar las valoraciones a una misma escala antes de aplicar umbrales.

4.7 Decisión frente a los criterios de éxito

¿Cumple el modelo los criterios definidos en la Fase 1? **No en su totalidad:** el modelo final cumple cinco de seis (Tabla 16). Cumple los de negocio y de ML y los de inferencia y tamaño; no cumple el de tiempo de entrenamiento, porque una corrida de 5 folds tomó 21,3 minutos frente a los 15 fijados. Parte de ese tiempo se debe a haber elegido `max_length = 384`: la corrida con 128 (E4) tomó 10,4 minutos. El modelo de solo texto no cumple ninguno de los criterios de desempeño.

Tabla 16. Decisión frente a los criterios de la Tabla 1.

Criterio y umbral	BART texto + metadatos (final)		BART solo texto	
	Valor	¿Cumple?	Valor	¿Cumple?
Recall de <i>negativo</i> en el hold-out $\geq 0,50$	0,900	Sí	0,100	No
F1 macro en el hold-out $\geq 0,784$	0,982	Sí	0,606	No
Accuracy en el hold-out $\geq 0,900$	0,997	Sí	0,863	No
Entrenamiento de 5 folds ≤ 15 min	21,3 min	No	21,1 min	No
Inferencia en GPU por lotes ≤ 100 ms por reseña	11,2 ms	Sí	no medido	–
Tamaño del modelo ≤ 1 GB	567 MB	Sí	no medido	–

Hay además una salvedad que los criterios no capturan. El modelo final los cumple leyendo la valoración del lugar, así que no resuelve el objetivo de negocio de detectar reseñas desfavorables por su contenido: la reseña «Mucha basura en la arena y nadie que responda, una decepción» recibe *neutral* o *positivo* según el lugar al que se asocie (Sección 5.2). Para ese objetivo haría falta reetiquetar los datos según el texto.

4.8 Aseguramiento de calidad

Tabla 17. QA de la Fase 4: riesgo, método aplicado y evidencia.

Riesgo	Método de QA	Evidencia
Diferencias debidas al azar	Intervalos por bootstrap y bootstrap pareado frente al baseline; tres semillas	Tabla 11; diferencia de $-0,037$ [$-0,077$; $+0,003$] para el modelo de solo texto
Leer la accuracy como comprensión del texto	Modelo de referencia de solo texto y pruebas sobre los metadatos	Con la reseña vacía la accuracy no cambia (Tabla 14)
Análisis de errores superficial	Revisión manual de los 48 errores, con categoría e hipótesis de causa	Tabla 13, Anexo B y errores_revisados_con_equipo.csv
Fragilidad ante texto real	Ocho perturbaciones con prueba unitaria de cada una	Tabla 14
Criterios ajustados a posteriori	Umbrales fijados en código antes de entrenar BART	Tabla 16: se reporta un «No» en tiempo de entrenamiento

Fase 5. Despliegue

5.1 Inferencia reproducible

El modelo final se guarda con sus pesos, su tokenizer y un archivo entrenamiento.json con la configuración. El guion inferencia.py parte solo de esa carpeta y del CSV de la competencia: reconstruye la entrada, predice por lotes y escribe el archivo de envío en formato numérico (python inferencia.py --modelo modelo_final --entrada submission.csv --salida submission.csv). El cuaderno lo ejecuta como un proceso aparte y compara el resultado con el envío generado durante el entrenamiento: coincide exactamente en las 129 filas (3 *negativo*, 101 *neutral* y 25 *positivo*). La prueba de humo de la Fase 3 ya había comprobado que un modelo guardado y recargado predice lo mismo que el original.

5.2 Demo

La demo es una función del cuaderno que clasifica una reseña nueva con los dos modelos, y tiene una interfaz opcional en Gradio que se deja apagada para que la ejecución completa no quede esperando. La Tabla 18 muestra cinco reseñas escritas para la prueba, que no están en los datos. La misma queja recibe *neutral* del modelo final si se le asocia un lugar con 4.0/5 y *positivo* si se le asocia uno con 8.8/10, y un comentario amable sobre la Plaza de Majagual recibe *negativo*. El modelo de solo texto marca todo *positivo* porque son textos cortos. Ninguno de los dos responde al contenido.

Tabla 18. Demo con reseñas nuevas: predicción de cada modelo y, entre paréntesis, su confianza.

Reseña nueva	Plataforma, lugar y valoración	Modelo final	Solo texto
La playa estaba limpia y el agua tranquila, volveríamos sin pensarlo.	Tripadvisor, Playas de Coveñas, 4.0/5	neutral (1,00)	positivo (0,94)
Mucha basura en la arena y nadie que responda, una decepción.	Tripadvisor, Playas de Coveñas, 4.0/5	neutral (1,00)	positivo (0,88)
Mucha basura en la arena y nadie que responda, una decepción.	Foursquare, Playas de Coveñas, 8.8/10	positivo (1,00)	positivo (0,88)
El mejor patacón de Sincelejo!!	Foursquare, Doki's comidas rápidas, 7.4/10	positivo (1,00)	positivo (0,99)
Plaza amplia, buena para caminar al atardecer.	Tripadvisor, Plaza de Majagual, 3.5/5	negativo (1,00)	positivo (0,99)

5.3 Costo

La Tabla 19 resume el costo del modelo final. Las latencias varían entre ejecuciones (de 11,2 a 12,1 ms por reseña en GPU por lotes y de 166 a 188 ms en CPU). No se hizo compresión por cuantización ni destilación, que la guía deja como opcional: el modelo cumple los umbrales de tamaño y latencia sin comprimir.

Tabla 19. Costo del modelo final, medido en una GPU Tesla T4 y en la CPU de la misma sesión de Kaggle.

Medida	Valor	Medida	Valor
Tamaño del modelo en disco	566,8 MB	Inferencia en GPU, una reseña a la vez	30,6 ms
Parámetros	140,0 millones	Inferencia en GPU, lotes de 32	11,2 ms por reseña
Memoria pico de GPU en inferencia (lotes de 32)	3546 MB	Inferencia en CPU, una reseña a la vez	165,9 ms
Entrenamiento del modelo final (4 épocas)	3,1 min	Entrenamiento de una corrida de 5 folds	21,3 min

Fase 6. Monitoreo y mantenimiento

6.1 Qué se monitorearía

Con el modelo en uso no hay etiquetas inmediatas, así que se vigilan señales que se pueden calcular con cada lote de reseñas nuevas. La Tabla 20 fija sus valores de referencia con los datos actuales y la condición que dispara una alerta.

Tabla 20. Señales de monitoreo del modelo final: valores de referencia y condición de alerta.

Señal	Train (CV)	Hold-out	Envío	Alerta
Predicciones <i>negativo / neutral / positivo</i> (%)	2,7 / 77,8 / 19,5	2,6 / 78,3 / 19,1	2,3 / 78,3 / 19,4	Cambio de más de 10 puntos en una clase durante un mes
Confianza media	1,00	1,00	1,00	Caída de más de 0,05 (señal débil: no reacciona al cambio de formato)
Palabras fuera del vocabulario de train (%)	0,00	8,35	8,92	Aumento de más de 5 puntos
Reseñas de Foursquare (%) y formato de la valoración	24,7	25,6	24,8	Plataforma nueva o valoración en otra escala
Palabras por reseña (mediana)	27	27	25	Sin umbral: contexto para leer las demás
Reseñas con palabras pegadas (%)	1,99	1,14	1,55	Sin umbral: contexto para leer las demás
Accuracy en una muestra etiquetada de 50 reseñas al mes	—	0,997	—	Cualquier error del modelo final (o menos de 0,85 con solo texto)

6.2 Simulación de drift

Evaluamos los dos modelos en subconjuntos del hold-out que representan un cambio de distribución (otra plataforma, otra época, otro destino, lugares no vistos y texto ruidoso) y, para el modelo final, en el cambio que de verdad lo afecta: que la valoración falte o llegue en otra escala, como pasaría al incorporar una plataforma nueva (Tabla 21).

El modelo de solo texto se degrada con cualquier cambio en la mezcla de plataformas: pierde entre 16 y 23 puntos en Foursquare, en las reseñas antiguas (casi todas de Foursquare) y en Sincelejo. El modelo final no se degrada en ninguno de esos subconjuntos, pero pierde entre 3 y 4 puntos cuando cambia el formato de la valoración. Y lo hace sin avisar: su confianza media es de 1,00 en todos los conjuntos, de modo que la confianza no sirve como alarma. Por eso el plan vigila directamente la plataforma de origen y el formato de la valoración.

6.3 Criterios de reentrenamiento y responsable

Se reentrena si una alerta se dispara dos meses seguidos, si cambia la escala o el formato de la valoración, si entra una plataforma o un municipio nuevo, o al acumular unas 200 reseñas etiquetadas nuevas. El reentrenamiento se hace con el mismo cuaderno, los mismos folds y la misma semilla, se registra en `experimentos.csv` y el modelo nuevo se compara con el

Tabla 21. Simulación de drift: accuracy en cada escenario y degradación frente al valor global del hold-out (0,863 y 0,997).

Escenario	n	BART solo texto	BART texto + metadatos
Solo Foursquare (cambia la mezcla de plataformas)	90	0,700 (-0,163)	1,000 (+0,003)
Reseñas de hasta 2014 (otra época)	85	0,682 (-0,181)	1,000 (+0,003)
Solo Sincelejo (otro destino: ciudad y no playa)	81	0,630 (-0,234)	1,000 (+0,003)
Lugares no vistos en el entrenamiento	8	0,875 (+0,012)	1,000 (+0,003)
Texto ruidoso: erratas en el 15 % de las letras	351	0,684 (-0,179)	0,997 (0,000)
Texto ruidoso: palabras pegadas	351	0,849 (-0,014)	0,997 (0,000)
Metadatos: sin valoración	351	0,863 (0,000)	0,957 (-0,040)
Metadatos: valoración de Tripadvisor en escala de 10	351	0,863 (0,000)	0,969 (-0,028)

vigente en el hold-out antes de reemplazarlo. La revisión mensual de las señales y la ejecución del reentrenamiento se alternan entre los dos integrantes, y la decisión de reemplazar el modelo se toma en conjunto.

6.4 Aseguramiento de calidad de las Fases 5 y 6

Tabla 22. QA de las Fases 5 y 6: riesgo, método aplicado y evidencia.

Riesgo	Método de QA	Evidencia
El envío no se puede regenerar	Guion independiente que parte del modelo guardado y se compara con el envío	Coincidencia exacta en las 129 filas
Costo mal estimado	Medición con calentamiento previo, en GPU y en CPU	Tabla 19; variación entre ejecuciones reportada
Degradación silenciosa en uso	Señales sin etiqueta y simulación de drift	Tablas 20 y 21: hasta -0,040 con confianza de 1,00

Cierre

Conclusiones

La pregunta de partida era si un Transformer ajustado podía clasificar el sentimiento de las reseñas turísticas de Sucre. Con estos datos, la respuesta tiene dos partes. Leyendo solo el texto, no: el mejor BART queda en una accuracy de 0,863, por debajo del baseline clásico (0,900), y más de la mitad de sus errores (26 de 48) son reseñas cuyo texto contradice la etiqueta. Leyendo además los metadatos del lugar, sí se predice la etiqueta de la competencia (0,997 en el hold-out y 1,00 en el leaderboard), pero eso equivale a leer una calificación.

Las tres hipótesis se cumplieron. El Transformer de solo texto no mejoró al baseline (H1); el modelo preentrenado en inglés rindió igual que el de español (H2), y con los metadatos la clasificación fue casi perfecta (H3). Las pruebas de robustez y de atribución lo explican: el modelo de texto clasifica por la forma del texto, que delata la plataforma, y el modelo final por la valoración y el nombre del lugar. Frente a los criterios de éxito, el modelo final cumple cinco de seis y falla el de tiempo de entrenamiento.

Lo que más valor aportó no fue el modelo sino el análisis exploratorio. Comprobar cómo se había construido la etiqueta, antes de entrenar nada, cambió la lectura de todos los resultados posteriores y evitó presentar un 1,00 como si fuera comprensión del lenguaje.

Limitaciones y trabajo futuro

El conjunto es pequeño y el hold-out tiene 10 negativos, de modo que las métricas de esa clase dependen de una o dos reseñas y sus intervalos son anchos. Casi todas las reseñas de evaluación son de lugares ya vistos, y lo poco que pudimos medir sobre lugares nuevos (8 reseñas) no permite concluir nada. El análisis de errores describe al modelo de solo texto, porque el final casi no falla, y su categorización refleja el criterio del equipo, sin un anotador externo que la contraste. No comparamos con un modelo multilingüe ni con encoders en español, y no probamos precisión mixta, que habría reducido el tiempo de entrenamiento.

Como trabajo futuro, lo primero es reetiquetar una muestra por el contenido del texto y llevar las valoraciones a una misma escala; sin eso, ninguna mejora del modelo se traduce en análisis de sentimiento. Lo segundo es validar por lugar, dejando lugares completos fuera del entrenamiento, para medir la generalización que en la práctica interesa. También quedan por evaluar la precisión mixta y la cuantización para bajar el costo.

Declaración de uso de IA generativa

Durante el desarrollo se utilizó de manera complementaria un asistente de IA generativa (Claude, de Anthropic) como herramienta de apoyo para algunas tareas de programación, análisis y redacción. El desarrollo, revisión y ejecución del cuaderno estuvieron a cargo del equipo, utilizando la herramienta únicamente como apoyo para resolver aspectos puntuales y proponer alternativas. Asimismo, se consultó para contrastar el diseño experimental, organizar una categorización preliminar de los errores de la Fase 4 y apoyar la elaboración inicial del documento.

Todo contenido sugerido por la herramienta fue revisado por el equipo antes de ser incorporado. Las decisiones finales, modificaciones, resultados, interpretaciones y validaciones fueron realizadas por los integrantes del equipo. El detalle de los usos de la herramienta, así como de las modificaciones y verificaciones efectuadas, se encuentra en la bitácora del Anexo A.

Contribución individual

Los dos integrantes trabajaron de forma conjunta en los cuatro roles que pide la guía (datos, modelado, evaluación y documentación) durante todo el proyecto, sin dividirlos por persona (Tabla 23).

Tabla 23. Contribución individual por actividad.

Actividad (rol)	Mateo Echeverría	Juan David López	Evidencia
Análisis de los datos y partición (datos)	Sí	Sí	Fases 1 y 2 del cuaderno
Baseline y experimentos de BART (modelado)	Sí	Sí	<code>experimentos.csv</code> ; versiones del cuaderno en Kaggle
Evaluación, errores y robustez (evaluación)	Sí	Sí	Fase 4 del cuaderno; envíos a la competencia
Despliegue y monitoreo (modelado, evaluación)	Sí	Sí	<code>inferencia.py</code> , <code>simulacion_drift.csv</code>
Repositorio y documento (documentación)	Sí	Sí	Historial de commits del repositorio

Referencias

- [1] S. Studer *et al.*, “Towards CRISP-ML(Q): A machine learning process model with quality assurance methodology,” *Mach. Learn. Knowl. Extr.*, vol. 3, n.º 2, pp. 392–413, 2021, doi: 10.3390/make3020020.
- [2] E. Puertas, “Traveler Insights UPTC 2026,” Kaggle, 2026. [En línea]. Disponible en: <https://www.kaggle.com/competitions/traveler-insights-uptc-2026>
- [3] D. Almanza Gonzalez, J. C. Martinez Santos y E. Puertas, “Dataset of Tourist Profiles in Sucre,” Zenodo, 2024, doi: 10.5281/zenodo.13240643.
- [4] R. Geirhos *et al.*, “Shortcut learning in deep neural networks,” *Nature Mach. Intell.*, vol. 2, n.º 11, pp. 665–673, 2020.
- [5] F. Pedregosa *et al.*, “Scikit-learn: Machine learning in Python,” *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.
- [6] M. Lewis *et al.*, “BART: Denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension,” en *Proc. 58th Annu. Meeting Assoc. Comput. Linguistics (ACL)*, 2020, pp. 7871–7880, doi: 10.18653/v1/2020.acl-main.703.
- [7] V. Araujo, M. M. Trusca, R. Tufiño y M.-F. Moens, “Sequence-to-sequence Spanish pre-trained language models,” en *Proc. Joint Int. Conf. Comput. Linguistics, Lang. Resour. Eval. (LREC-COLING)*, Turín, Italia, 2024, pp. 14729–14743.
- [8] Y. Tang *et al.*, “Multilingual translation with extensible multilingual pretraining and finetuning,” arXiv:2008.00401, 2020.
- [9] A. Vaswani *et al.*, “Attention is all you need,” en *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 30, 2017, pp. 5998–6008.
- [10] A. Paszke *et al.*, “PyTorch: An imperative style, high-performance deep learning library,” en *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 32, 2019, pp. 8024–8035.
- [11] T. Wolf *et al.*, “Transformers: State-of-the-art natural language processing,” en *Proc. 2020 Conf. Empirical Methods Natural Lang. Process.: Syst. Demonstrations*, 2020, pp. 38–45, doi: 10.18653/v1/2020.emnlp-demos.6.
- [12] I. Loshchilov y F. Hutter, “Decoupled weight decay regularization,” en *Proc. Int. Conf. Learn. Representations (ICLR)*, 2019.
- [13] B. Efron y R. J. Tibshirani, *An Introduction to the Bootstrap*. Nueva York, NY, EE.UU.: Chapman & Hall, 1993.
- [14] M. D. Zeiler y R. Fergus, “Visualizing and understanding convolutional networks,” en *Computer Vision – ECCV 2014*, Lecture Notes in Computer Science, vol. 8689. Cham, Suiza: Springer, 2014, pp. 818–833.

Anexo A. Bitácora de uso de IA generativa

Herramienta en todas las entradas: Claude (Anthropic), a través de su aplicación. Cada fila resume un uso: para qué se pidió, qué se pidió, qué se aceptó, qué se corrigió y cómo se validó. Lo corregido incluye tanto los errores de la herramienta como las decisiones en las que el equipo se apartó de lo que esta proponía.

Tabla 24. Bitácora de uso de IA generativa.

Fecha	Propósito	Prompt resumido	Qué se aceptó	Qué se corrigió	Cómo se validó
5 oct.	Comprender la guía y organizar el trabajo	Consulta sobre los requerimientos de la actividad, las fases y los criterios de la rúbrica.	Se tomaron como referencia algunas sugerencias para organizar las actividades y verificar que se cubrieran los requisitos.	El equipo ajustó la planificación de acuerdo con la guía, la rúbrica, los recursos disponibles y los objetivos del proyecto.	Revisión directa de la guía y la rúbrica por parte del equipo.
5 oct.	Análisis exploratorio y baseline	Consultas sobre el tratamiento inicial de los datos, las etiquetas y posibles alternativas para establecer el baseline.	Se utilizaron algunas orientaciones para comprender el problema y estructurar el análisis inicial.	El procesamiento, la representación de los datos y la configuración definitiva fueron establecidos por el equipo.	Ejecución del cuaderno en Kaggle y comprobación de las métricas obtenidas.
5 oct.	Selección del checkpoint	Consulta sobre la diferencia entre la arquitectura BART y los checkpoints disponibles.	Se utilizó la explicación para aclarar las diferencias entre arquitectura y checkpoint.	La selección definitiva del modelo se realizó considerando idioma, licencia, número de parámetros y recursos computacionales disponibles.	Consulta de las fichas de los modelos y prueba de funcionamiento realizada por el equipo.
6 oct.	Organización del repositorio	Consulta sobre una estructura inicial para organizar los archivos y documentar el proyecto.	Se tomó como referencia una estructura básica de organización.	El equipo definió la estructura definitiva y los archivos que serían incluidos.	Repositorio creado, organizado y cargado por el equipo.
6 oct.	Fine-tuning de BART	Consultas puntuales sobre implementación del entrenamiento, parámetros y posibles problemas durante la ejecución.	Se utilizaron algunas sugerencias para orientar la implementación y revisar alternativas de configuración.	El equipo seleccionó los parámetros definitivos, realizó las nueve corridas y ajustó la configuración según los resultados y recursos disponibles.	Pruebas de humo y ejecuciones completas de los experimentos.
6 oct.	Diagnóstico de errores de ejecución	Se proporcionaron mensajes de error para consultar posibles causas y alternativas de solución.	Se consideraron las posibles causas identificadas como orientación para localizar el problema.	El equipo determinó qué cambios realizar y descartó las alternativas que no correspondían al problema encontrado.	Nueva ejecución del código hasta obtener una ejecución sin errores.
7 oct.	Lectura e interpretación de resultados	Consultas sobre la interpretación de las métricas y comparación del modelo con el baseline.	Se utilizaron algunas explicaciones para facilitar la interpretación de los resultados.	El equipo realizó la comparación definitiva y decidió qué modelo utilizar de acuerdo con los resultados obtenidos.	Validación cruzada, hold-out y resultados obtenidos en las pruebas realizadas.
7 oct.	Evaluación, despliegue y monitoreo	Consultas puntuales sobre evaluación, robustez, inferencia, costos y monitoreo del modelo.	Se utilizaron sugerencias como apoyo para revisar los aspectos que debían evaluarse.	Se corrigieron afirmaciones que no coincidían con los resultados reales y se ajustó el orden de algunas actividades.	Tres ejecuciones completas y comparación de las métricas obtenidas.
7–8 oct.	Categorización de errores	Consulta para obtener posibles criterios de clasificación de los errores del modelo de solo texto.	Las categorías propuestas se utilizaron únicamente como punto de partida para organizar la revisión.	El equipo revisó individualmente los 48 errores, modificó 5 categorías y redactó nuevamente las causas de acuerdo con su propio criterio.	Revisión manual de los 48 casos. La clasificación final coincidió con la propuesta inicial en 43 casos.
8 oct.	Revisión del documento	Consultas puntuales para detectar errores de redacción, ortografía y claridad en algunos apartados.	Se consideraron algunas sugerencias de corrección lingüística.	El contenido técnico, resultados, análisis y conclusiones fueron elaborados por el equipo; únicamente se realizaron ajustes de redacción cuando fueron necesarios.	Revisión final del documento por los integrantes del equipo y contraste con el cuaderno y los resultados obtenidos.

Nota: La herramienta de IA generativa se utilizó como recurso complementario para consultas, aclaración de conceptos, revisión de errores y sugerencias. La implementación, experimentación, validación de resultados, interpretación y decisiones finales fueron realizadas por los integrantes del equipo.

Anexo B. Errores revisados del modelo de solo texto

Los 48 errores del BART de solo texto en el hold-out, agrupados por la categoría que les asignó el equipo en su revisión manual. «Conf.» es la probabilidad que el modelo asignó a su predicción en la versión final del cuaderno. Las hipótesis no citan el texto de las reseñas que nombran personas.

Tabla 25. Errores del modelo de solo texto en el hold-out, con la categoría y la hipótesis de causa de la revisión manual.

ID	Plataforma	Valor.	Etiqueta → predicción	Conf.	Hipótesis de causa
Error de etiqueta (26)					
256	Foursquare	6.9/10	neutral → positivo	0,99	Recomendación y “buenísima” expresan una opinión positiva clara; la etiqueta neutral no representa el texto.
257	Foursquare	6.9/10	neutral → positivo	0,99	Elogio explícito (“deliciosa”) pero la etiqueta es neutral; la discrepancia está en la etiqueta, no en el modelo.
273	Foursquare	6.8/10	neutral → positivo	0,90	Es un elogio enfático y directo (“lo mejor”, “historia se partió en 2”), pero la etiqueta es neutral.
287	Foursquare	6.8/10	neutral → positivo	0,98	“Que bueno” y “se nota el progreso” expresan valoración positiva, no neutral.
288	Foursquare	6.8/10	neutral → positivo	0,98	“Super chevereee” y “muy bn” son expresiones positivas; la etiqueta neutral no refleja el texto.
295	Foursquare	6.8/10	neutral → positivo	0,96	“De los mejores” expresa una valoración positiva muy clara, pero la etiqueta es neutral.
296	Foursquare	6.8/10	neutral → positivo	0,99	“No puede faltar” y “recomendados” son una recomendación positiva clara frente a la etiqueta neutral.
300	Foursquare	6.7/10	neutral → positivo	0,41	“Mejor atención” y la recomendación de productos expresan una opinión positiva, no neutral.
302	Foursquare	6.7/10	neutral → positivo	0,94	“Delicioso” y “los mejores” son elogios directos, incompatibles con neutral.
305	Foursquare	6.7/10	neutral → negativo	0,43	“Exquisito”, “mejor lugar” y “hogareño” son elogios directos; la etiqueta neutral no coincide.
307	Foursquare	6.7/10	neutral → positivo	0,99	“Recomiendo” expresa valoración positiva; la etiqueta neutral no coincide con el contenido.
308	Foursquare	6.7/10	neutral → positivo	0,99	“Deliciosa” y “mejor pedir las” expresan valoración positiva, incompatible con neutral.
319	Foursquare	6.4/10	neutral → positivo	0,99	“Buenas hamburguesas” es una valoración positiva directa, pero figura como neutral.
468	Tripadvisor	4.5/5	neutral → negativo	0,48	Es un elogio inequívoco (“paraíso”, “espectaculares”, “visita obligada”), incompatible con neutral.
503	Tripadvisor	4.5/5	neutral → positivo	0,86	El texto es un elogio muy marcado (“espectacular”, “A1”, “me gustó más”), pero está etiquetado como neutral.
575	Tripadvisor	4.5/5	neutral → positivo	0,58	Es una recomendación entusiasta y describe atractivos del paseo; la etiqueta neutral no representa la opinión.
585	Tripadvisor	4.5/5	neutral → negativo	0,47	“Espectacular” y “relajación total” son valoraciones positivas claras, aunque la etiqueta sea neutral.
732	Tripadvisor	4.0/5	neutral → positivo	0,50	Todo el texto es favorable (“buen sitio”, “bien ubicada”, “buen estado”, “agradable”), pero figura como neutral.
784	Tripadvisor	4.0/5	neutral → positivo	0,90	El texto está lleno de recomendaciones y elogios (“hermosas”, “lo máximo”, “hermosísimo”), pero la etiqueta es neutral.
866	Tripadvisor	3.5/5	negativo → neutral	0,80	El texto recomienda visitar la plaza y enumera atributos positivos; la etiqueta negativa no coincide con el contenido.
868	Tripadvisor	3.5/5	negativo → neutral	0,68	El texto califica el paseo como agradable e imperdible; la etiqueta negativa contradice directamente el contenido.
876	Tripadvisor	3.5/5	negativo → neutral	0,71	La descripción es principalmente positiva/neutra y no presenta una crítica clara que sustente la etiqueta negativa.
879	Tripadvisor	3.5/5	negativo → neutral	0,85	La descripción es mayoritariamente positiva/neutra y no contiene una crítica clara que justifique negativo.
880	Tripadvisor	3.5/5	negativo → neutral	0,79	“Famosa”, “monumental”, “hermosos” y “Recomendado” son señales positivas claras frente a la etiqueta negativa.
881	Tripadvisor	3.5/5	negativo → neutral	0,98	El texto es predominantemente elogioso y termina en “Fantástica”; la etiqueta negativa contradice el contenido.
886	Tripadvisor	3.5/5	negativo → neutral	0,91	El texto es claramente positivo (“cálida”, “cristal”, “recomendadísima”), mientras la etiqueta es negativa.
No es una reseña (7)					
215	Foursquare	7.3/10	positivo → neutral	0,93	Es una pregunta sobre alojamiento y precios, no una reseña/opinión del lugar.
258	Foursquare	6.9/10	neutral → positivo	0,99	Es solo el nombre de un producto/plato, sin una opinión completa.
294	Foursquare	6.8/10	neutral → positivo	0,99	Es solo una lista de establecimientos/productos, sin una valoración explícita.
312	Foursquare	6.7/10	neutral → positivo	0,98	Es un fragmento incompleto (“Las pizzas de”), sin contenido suficiente para expresar una opinión.

ID	Plataforma	Valor.	Etiqueta → predicción	Conf.	Hipótesis de causa
943	Tripadvisor	5.0/5	neutral → positivo	0,99	Es una respuesta de agradecimiento del negocio a un usuario, no una opinión sobre el lugar.
946	Tripadvisor	5.0/5	neutral → positivo	0,96	Es una respuesta de agradecimiento del negocio (“Siempre bienvenida”), no una reseña.
1080	Tripadvisor	5.0/5	neutral → positivo	0,99	Es una respuesta conversacional (“muy pronto lo harás”), no una reseña del lugar.
Reseña mixta (7)					
37	Foursquare	8.8/10	positivo → neutral	0,73	Combina una queja fuerte sobre las vías con aspectos favorables sobre restaurantes y el plan de viaje; la polaridad es mixta.
177	Foursquare	7.6/10	positivo → neutral	0,71	Elogia fuertemente la hamburguesa pero critica el tiempo de espera; ambos polos aparecen en la misma reseña.
207	Foursquare	7.3/10	positivo → neutral	0,36	Elogia precios/tamaño, pero señala una falla en la limpieza; la combinación de positivo y negativo puede confundir al modelo.
361	Tripadvisor	4.5/5	neutral → positivo	0,97	Combina atractivos positivos con una dificultad de accesibilidad; esa mezcla puede llevar al modelo a una polaridad simple.
856	Tripadvisor	3.5/5	negativo → neutral	0,86	Hay valoración positiva de la plaza, pero también una crítica explícita a la administración por no cuidarla; la mezcla justifica la etiqueta negativa.
869	Tripadvisor	3.5/5	negativo → neutral	0,94	Predominan aspectos positivos, pero también señala una falla concreta: la fuente no funciona; la mezcla puede confundir al modelo.
895	Tripadvisor	4.5/5	neutral → negativo	0,52	Elogia las playas pero introduce una condición negativa: mejorar gastronomía y servicio; es una valoración mixta.
Texto con ruido (4)					
166	Foursquare	7.7/10	positivo → neutral	0,39	Hay palabras concatenadas (“unacerveza”, “heladay”) que pueden impedir reconocer las señales positivas.
183	Foursquare	7.6/10	positivo → neutral	0,82	Las palabras están concatenadas y deformadas (“Elsolomillorecomendado”, “Lasyucascomsuo”), lo que dificulta identificar la opinión.
194	Foursquare	7.4/10	positivo → neutral	0,86	Las palabras aparecen pegadas (“Lahamburguesaespecial”, “contocineta”, “losdesgranados”), dificultando la lectura del clasificador.
533	Tripadvisor	4.5/5	neutral → positivo	0,52	Hay errores y deformaciones como “Aguas nive” y “vsit”, además de repetición; ese ruido puede dificultar la clasificación.
Crítica no detectada (2)					
261	Foursquare	6.9/10	neutral → positivo	0,99	La etiqueta neutral es parcialmente plausible, pero “feas playas” contiene una crítica explícita que el modelo ignoró.
293	Foursquare	6.8/10	neutral → positivo	0,98	“Poca variedad” es una crítica directa; neutral puede ser una etiqueta intermedia, pero el modelo la llevó a positivo.
Sesgo de plataforma (1)					
285	Foursquare	6.8/10	neutral → positivo	0,99	“Decente” es una valoración tibia compatible con neutral; el modelo pudo asociar Foursquare y vocabulario positivo con positivo.
Negación (1)					
286	Foursquare	6.8/10	neutral → positivo	0,90	“No es que sea la gran cosa” contiene una negación que invierte o atenúa el significado de la expresión positiva.

Anexo C. Detalle de los experimentos

Tabla 26. F1 macro de validación en cada fold y, entre paréntesis, la mejor época. La media de los folds difiere levemente del F1 macro de la Tabla 9, que se calcula sobre todas las predicciones fuera de fold.

ID	Fold 0	Fold 1	Fold 2	Fold 3	Fold 4	Media	Desv.
E1	0,603 (3)	0,560 (2)	0,674 (7)	0,565 (5)	0,599 (4)	0,600	0,041
E2	0,595 (3)	0,565 (3)	0,539 (1)	0,577 (3)	0,593 (1)	0,574	0,021
E3	0,579 (3)	0,557 (1)	0,718 (8)	0,580 (5)	0,812 (7)	0,649	0,099
E4	0,598 (6)	0,562 (2)	0,562 (4)	0,565 (2)	0,599 (4)	0,577	0,017
E5	0,563 (1)	0,562 (6)	0,556 (7)	0,574 (3)	0,593 (4)	0,570	0,013
E6	0,596 (5)	0,601 (4)	0,576 (4)	0,592 (3)	0,650 (8)	0,603	0,025
E7a	0,603 (7)	0,629 (5)	0,556 (6)	0,572 (3)	0,683 (7)	0,609	0,045
E7b	0,591 (4)	0,551 (1)	0,554 (5)	0,591 (5)	0,824 (6)	0,622	0,102
E8	1,000 (4)	1,000 (3)	1,000 (4)	1,000 (4)	1,000 (3)	1,000	0,000

Tabla 27. Diagnóstico de sobreajuste: pérdida media en la última época entrenada y época en que la validación fue mínima.

	E1	E2	E3	E4	E5	E6	E7a	E7b	E8
Pérdida de entrenamiento	0,091	0,232	0,170	0,142	0,145	0,084	0,413	0,167	0,001
Pérdida de validación	0,588	0,476	0,438	0,280	0,460	0,389	0,465	0,336	0,000
Época del mínimo de validación	3	3	3	7	3	5	3	8	6

Artefactos que genera el cuaderno. `folds.csv` (partición), `experimentos.csv` (registro), `experimentos/*.pkl` (predicciones y curvas de cada corrida), `modelo_final/` (pesos, tokenizer y configuración), `inferencia.py`, `submission.csv` (envío del modelo final), `submission_solo_texto.csv`, `errores_revisados.csv` y `simulacion_drift.csv`. La revisión manual de los errores, con la categorización preliminar al lado, está en `errores_revisados_con_equipo.csv`.